

GRADO EN CIENCIA DE DATOS



VNIVERSITAT
DE VALÈNCIA

TRABAJO FIN DE GRADO

DIAGNÓSTICO DE LESIONES DE RODILLA UTILIZANDO IMÁGENES DE RESONANCIA MAGNÉTICA

AUTOR:

PABLO LÓPEZ DOMÍNGUEZ

TUTORES:

**JOSÉ DAVID MARTÍN GUERRERO
YOLANDA VIVES GILABERT**



VNIVERSITAT
DE VALÈNCIA



Escola Tècnica Superior
d'Enginyeria **ETSE-UV**

TRABAJO FIN DE GRADO

DIAGNÓSTICO DE LESIONES DE RODILLA UTILIZANDO IMÁGENES DE RESONANCIA MAGNÉTICA

AUTOR: PABLO LÓPEZ DOMÍNGUEZ

JOSÉ DAVID MARTÍN GUERRERO
TUTORES: YOLANDA VIVES GILABERT

Declaración de autoría:

Yo, Pablo López Domínguez, declaro la autoría del Trabajo Fin de Grado titulado “Diagnóstico de lesiones de rodilla utilizando imágenes de resonancia magnética” y que el citado trabajo no infringe las leyes en vigor sobre propiedad intelectual. El material no original que figura en este trabajo ha sido atribuido a sus legítimos autores.

Valencia, 9 de junio de 2026

Fdo: Pablo López Domínguez

Resumen:

El diagnóstico de lesiones de rodilla mediante imágenes de resonancia magnética (RM) constituye un proceso fundamental en la práctica clínica, que exige un elevado grado de especialización y un considerable consumo de tiempo por parte de los profesionales sanitarios. En este contexto, el presente trabajo aborda la aplicación de técnicas avanzadas de aprendizaje profundo con el objetivo de automatizar y optimizar la detección de patologías en imágenes médicas.

Concretamente, se han implementado y evaluado tres arquitecturas representativas del estado del arte en visión por computador: una red neuronal convolucional profunda (ResNet) y dos modelos basados en mecanismos de atención tipo transformer (Vision Transformer y Swin Transformer). Dichos modelos han sido entrenados y validados sobre un conjunto de datos de imágenes de resonancia magnética de rodilla, con el propósito de analizar su capacidad para identificar patrones relevantes asociados a distintos tipos de lesiones.

Los resultados obtenidos permiten establecer una comparación rigurosa entre los diferentes enfoques, poniendo de manifiesto las ventajas y limitaciones de cada arquitectura en términos de precisión, capacidad de generalización y eficiencia computacional. Asimismo, se discuten las implicaciones de estos hallazgos en el ámbito clínico, así como las principales limitaciones del estudio.

Finalmente, se proponen diversas líneas de investigación futura orientadas a mejorar la robustez y la aplicabilidad de estos modelos en entornos clínicos reales. Este trabajo contribuye al avance del uso de técnicas de aprendizaje profundo en el diagnóstico médico, evidenciando el potencial de las arquitecturas basadas en transformers frente a enfoques tradicionales basados en convoluciones.

Abstract:

The diagnosis of knee injuries using magnetic resonance imaging (MRI) is a fundamental task in clinical practice, requiring a high level of expertise and a significant investment of time from medical professionals. In this context, this work explores the application of advanced deep learning techniques with the aim of automating and enhancing the detection of pathologies in medical images.

Specifically, three representative state-of-the-art computer vision architectures have been implemented and evaluated: a deep convolutional neural network (ResNet) and two transformer-based models (Vision Transformer and Swin Transformer). These models have been trained and validated on a dataset of knee MRI images in order to assess their ability to identify relevant patterns associated with different types of injuries.

The obtained results enable a rigorous comparison between the different approaches, highlighting the strengths and limitations of each architecture in terms of accuracy, generalization capability, and computational efficiency. Furthermore, the implications of these findings in the clinical domain are discussed, along with the main limitations of the study.

Finally, several future research directions are proposed to improve the robustness and applicability of these models in real clinical environments. This work contributes to the advancement of deep learning techniques in medical diagnosis, demonstrating the potential of transformer-based architectures compared to traditional convolutional approaches.

Resumen:

El diagnòstic de lesions de genoll mitjançant imatges de ressonància magnètica (RM) constitueix una tasca fonamental en la pràctica clínica, que requereix un alt nivell d'especialització i un considerable consum de temps per part dels professionals sanitaris. En aquest context, el present treball aborda l'aplicació de tècniques avançades d'aprenentatge profund amb l'objectiu d'automatitzar i millorar la detecció de patologies en imatges mèdiques.

Concretament, s'han implementat i avaluat tres arquitectures representatives de l'estat de l'art en visió per computador: una xarxa neuronal convolucional profunda (ResNet) i dos models basats en mecanismes d'atenció de tipus transformer (Vision Transformer i Swin Transformer). Aquests models han sigut entrenats i validats sobre un conjunt de dades d'imatges de ressonància magnètica de genoll, amb la finalitat d'analitzar la seua capacitat per identificar patrons rellevants associats a diferents tipus de lesions.

Els resultats obtinguts permeten establir una comparació rigorosa entre els diferents enfocaments, posant de manifest les fortaleses i limitacions de cada arquitectura en termes de precisió, capacitat de generalització i eficiència computacional. Així mateix, es discuteixen les implicacions d'aquests resultats en l'àmbit clínic, així com les principals limitacions de l'estudi.

Finalment, es proposen diverses línies de treball futur orientades a millorar la robustesa i l'aplicabilitat d'aquests models en entorns clínics reals. Aquest treball contribueix a l'avanç de les tècniques d'aprenentatge profund en el diagnòstic mèdic, evidenciant el potencial de les arquitectures basades en transformers enfront dels enfocaments tradicionals basats en convolucions.

Agradecimientos:

En primer lugar, quiero expresar mi más sincero agradecimiento a mis tutores, David y Yolanda, por su orientación, apoyo y dedicación a lo largo de la realización de este trabajo. Su experiencia, sus consejos y su disponibilidad han sido fundamentales para el desarrollo de este proyecto.

Asimismo, me gustaría agradecer a todos los profesores que han formado parte de mi formación académica durante estos años, por haber contribuido a mi aprendizaje y haber despertado mi interés por el ámbito de la Ciencia de Datos.

De manera especial, quiero dar las gracias a mis amigos y compañeros, por su apoyo constante, motivación y por compartir conmigo este camino.

Quiero también agradecer especialmente a Laura, por haberme apoyado de manera incondicional durante toda la carrera, por su paciencia, su comprensión y por haber estado a mi lado incluso en los momentos más difíciles. Este camino habría sido mucho más difícil sin ti.

Finalmente, quiero expresar mi más profundo agradecimiento a mi familia y seres queridos, por su apoyo incondicional, su paciencia y su confianza en mí a lo largo de toda esta etapa. Sin ellos, nada de esto habría sido posible.

Índice general

1. Introducción	17
1.1. Contexto y Motivación	17
1.2. Objetivos	18
1.3. Estado del Arte	19
1.3.1. El conjunto de datos MRNet como referencia	19
1.3.2. Primeros enfoques basados en redes convolucionales (ResNet)	20
1.3.3. Vision Transformers (ViT)	21
1.3.4. Swin Transformers	21
1.3.5. Comparativa sistemática según protocolo de validación	22
1.3.6. Síntesis y posicionamiento del presente trabajo	23
2. Materiales	25
2.1. Conjuntos de datos	25
2.1.1. MRNet	25
2.1.2. Conjunto externo de Croacia	26
2.2. Representación y preprocesamiento de datos	26
3. Métodos	27
3.1. Descripción general del sistema	27
3.2. Selección automática de cortes anatómicos	27
3.2.1. Estrategias evaluadas	28
3.3. Arquitecturas de aprendizaje profundo	29
3.4. Redes Convolucionales	29
3.4.1. ResNet50	29
3.5. Vision Transformers	31
3.5.1. ViT-Base	31
3.6. Swin Transformers	32
3.6.1. Swin-Small	32
4. Resultados y Discusión	35

4.0.1. Diseño experimental y criterios de evaluación clínica	35
4.0.2. Resultados del modelo convolucional ResNet50	36
4.0.3. Resultados del modelo Vision Transformer (ViT-Base)	39
4.0.4. Resultados del modelo Swin Transformer Small	42
4.0.5. Comparativa final de ensambles en MRNet	45
4.0.6. Validación externa zero-shot en el conjunto de datos de Croacia . .	46
4.0.7. Adaptación de dominio mediante fine-tuning en Croacia	47
4.0.8. Discusión general de los resultados	48
5. Conclusiones (obligatorio) y proyección futura.	49
5.1. Conclusiones	49
5.2. Trabajo futuro	49
Bibliografía	49

Capítulo 1

Introducción

1.1. Contexto y Motivación

El diagnóstico de lesiones de rodilla constituye un desafío relevante en el ámbito de la medicina deportiva, especialmente en contextos de alta exigencia física donde la incidencia de patologías articulares, como la rotura del ligamento cruzado anterior (ACL), es especialmente elevada. Este tipo de lesiones no solo tiene un impacto inmediato en el rendimiento deportivo, sino que también puede condicionar la trayectoria profesional de los deportistas y afectar a su calidad de vida a largo plazo.

En estos escenarios, la resonancia magnética (RM) se erige como una herramienta fundamental para la evaluación clínica, permitiendo la identificación precisa de lesiones en estructuras internas de la articulación como ligamentos, meniscos o cartílago. Su carácter no invasivo y su alta capacidad de resolución la convierten en una técnica indispensable dentro del proceso diagnóstico. No obstante, la interpretación de estas imágenes requiere un alto grado de especialización y experiencia por parte de los radiólogos.

En la práctica clínica, este proceso de análisis suele estar condicionado por la elevada carga asistencial, lo que puede traducirse en tiempos de espera significativos para la obtención de un informe diagnóstico. Esta situación resulta especialmente crítica en contextos deportivos, donde la rapidez en la toma de decisiones puede influir directamente en el tratamiento, la recuperación y la planificación del retorno a la actividad.

La motivación de este trabajo surge tanto del interés académico como de la experiencia personal en el ámbito del deporte de alto nivel durante la etapa de formación, compitiendo en entornos de elevada exigencia. Este tipo de contextos, caracterizados por una gran intensidad competitiva y física, implican también una mayor exposición a lesiones de gravedad.

En este sentido, he sufrido varias lesiones de rodilla de carácter severo, incluyendo roturas del ligamento cruzado anterior, que han requerido múltiples intervenciones quirúrgicas y un seguimiento clínico prolongado basado en la realización de numerosas resonancias magnéticas. A lo largo de este proceso, he podido observar de manera directa no solo la importancia crítica del diagnóstico por imagen, sino también las limitaciones existentes en términos de tiempo de respuesta, acceso a especialistas y necesidad de interpretación experta.

Esta experiencia despertó un interés inicial por comprender e interpretar las imágenes de resonancia magnética de rodilla, motivado tanto por la necesidad personal como por la

curiosidad técnica. Paralelamente, durante el desarrollo del Grado en Ciencia de Datos, los conocimientos adquiridos en áreas como el aprendizaje automático, el análisis de datos y la visión por computador permitieron identificar el potencial de estas tecnologías para abordar problemas complejos en el ámbito médico.

En los últimos años, el avance de las técnicas de aprendizaje profundo ha supuesto un cambio significativo en el campo de la visión por computador, permitiendo desarrollar modelos capaces de extraer patrones complejos a partir de grandes volúmenes de datos. Estas capacidades abren la puerta a su aplicación en el análisis de imágenes médicas, donde pueden actuar como herramientas de apoyo en la detección de patologías.

A partir de esta combinación de experiencia personal y formación académica, surge la idea de explorar el uso de herramientas basadas en aprendizaje profundo para asistir en la detección de lesiones a partir de imágenes médicas. De este modo, este proyecto se sitúa en la intersección entre una problemática clínica real y las capacidades tecnológicas actuales, con la finalidad de analizar posibles soluciones que contribuyan a mejorar la eficiencia del proceso diagnóstico y el apoyo a los profesionales sanitarios.

1.2. Objetivos

El objetivo principal de este trabajo es analizar el potencial de técnicas de aprendizaje profundo en la detección de lesiones de rodilla a partir de imágenes de resonancia magnética, evaluando su aplicabilidad como herramientas de apoyo en el ámbito clínico.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- Estudiar el estado del arte en el uso de técnicas de visión por computador y aprendizaje profundo aplicadas al análisis de imágenes médicas, con especial atención al diagnóstico de lesiones de rodilla.
- Seleccionar, implementar y adaptar distintas arquitecturas representativas del estado del arte, incluyendo modelos basados en redes neuronales convolucionales (ResNet) y modelos basados en transformers (Vision Transformer y Swin Transformer).
- Preparar y procesar un conjunto de datos de imágenes de resonancia magnética de rodilla, incluyendo tareas de preprocesado, normalización y partición en conjuntos de entrenamiento, validación y prueba.
- Entrenar los modelos seleccionados y ajustar sus parámetros con el fin de optimizar su rendimiento en la tarea de clasificación o detección de lesiones.
- Evaluar de forma rigurosa el rendimiento de los diferentes modelos mediante métricas adecuadas, analizando su precisión, capacidad de generalización y eficiencia computacional.
- Comparar los resultados obtenidos entre las distintas arquitecturas, identificando sus principales fortalezas y limitaciones en el contexto del problema abordado.
- Analizar la viabilidad del uso de estos modelos como herramientas de apoyo al diagnóstico clínico, considerando tanto sus ventajas como sus posibles limitaciones en entornos reales.

1.3. Estado del Arte

En los últimos años, el uso de técnicas de aprendizaje profundo en imagen médica ha experimentado un crecimiento notable, especialmente en tareas de clasificación, detección y segmentación sobre imágenes de resonancia magnética (RM). En el caso concreto del diagnóstico de lesiones de rodilla, este avance ha estado impulsado por la disponibilidad de conjuntos de datos públicos y por la mejora progresiva de las arquitecturas de visión por computador. En este contexto, la detección automatizada de lesiones del ligamento cruzado anterior (LCA) a partir de imágenes de resonancia magnética se ha consolidado como una línea de investigación de gran relevancia.

A nivel metodológico, una parte importante de la investigación reciente se ha centrado en el desarrollo de modelos de clasificación directa de extremo a extremo (*end-to-end*). Aunque existen propuestas que plantean sistemas híbridos basados en una segmentación o localización previa de la región de interés antes de realizar la clasificación, este Trabajo de Fin de Grado se enmarca dentro de los enfoques de clasificación directa. Esta decisión responde a criterios de aplicabilidad práctica y viabilidad clínica, fundamentados en tres razones principales:

- **Coste de anotación:** Los modelos de segmentación requieren máscaras detalladas a nivel de píxel o vóxel, delineadas manualmente por radiólogos expertos en cada uno de los cortes bidimensionales del volumen. Este proceso supone un recurso limitado y costoso en el ámbito médico.
- **Propagación del error:** En sistemas en cascada, formados por una etapa de segmentación seguida de una etapa de clasificación, cualquier imprecisión cometida al delimitar el ligamento puede trasladarse al clasificador y afectar al diagnóstico final.
- **Preservación de signos indirectos de lesión:** En la práctica clínica, el estado del ligamento no se evalúa de forma aislada, sino junto con indicios periféricos relevantes, como el edema óseo por contusión (*bone bruising*) en el cóndilo femoral lateral o la traslación tibial anterior. Un clasificador directo procesa el volumen completo de la articulación, permitiendo al modelo aprender estas relaciones contextuales.

Por todo ello, la comparación sistemática entre arquitecturas convolucionales y modelos basados en mecanismos de atención aplicados a la clasificación directa constituye uno de los ejes principales del debate científico actual y del presente trabajo.

1.3.1. El conjunto de datos MRNet como referencia

Uno de los principales hitos en este ámbito es la publicación del conjunto de datos *MRNet*, desarrollado por el *Stanford Machine Learning Group* en 2018 [1], que se ha convertido en una referencia habitual para la evaluación de modelos de aprendizaje profundo aplicados al análisis de resonancias magnéticas de rodilla. Este dataset está compuesto por 1.370 estudios de RM de rodilla e incluye etiquetas para tres tareas diagnósticas: anormalidad general, lesión meniscal y rotura del ligamento cruzado anterior.

Para el estudio del LCA, la serie sagital ponderada en T2 con supresión grasa resulta especialmente relevante, ya que permite visualizar con claridad la continuidad de las fibras del ligamento. No obstante, uno de los aspectos más importantes al revisar la

literatura es que los protocolos de evaluación no siempre son homogéneos, lo que dificulta la comparación directa entre trabajos.

En particular, conviene distinguir entre la nomenclatura empleada en el artículo original y la utilizada en el contexto competitivo asociado a MRNet. En muchos trabajos posteriores, el conjunto de validación pública se utiliza como referencia principal, mientras que el denominado *hidden test set* permanece oculto y solo puede evaluarse mediante la plataforma de competición de Stanford. Como consecuencia, gran parte de los resultados reportados en la literatura corresponden a validación pública o a particiones propias definidas por los autores, y no al conjunto de test oculto.

Cuadro 1.1: Correspondencia entre las particiones de MRNet y su uso en el artículo original y en la competición.

Segmento	N.º de estudios	Artículo original	Uso habitual posterior
Entrenamiento	1130	<i>Training set</i>	<i>Training set</i>
Validación pública	120	<i>Tuning set</i>	<i>Validation set</i>
Test oculto	120	<i>Validation set</i>	<i>Hidden test set</i>

Esta distinción es especialmente importante desde el punto de vista metodológico, ya que un resultado obtenido sobre validación pública no debe interpretarse como directamente comparable con otro obtenido sobre el test oculto. En consecuencia, cualquier revisión del estado del arte debe considerar no solo la métrica reportada, sino también el protocolo exacto de evaluación empleado.

1.3.2. Primeros enfoques basados en redes convolucionales (ResNet)

El trabajo original de *MRNet* supuso un punto de partida fundamental en este campo [1]. Su propuesta se basó en el uso de una arquitectura convolucional tipo AlexNet preentrenada en ImageNet, combinada con una operación de *max-pooling* a través de los distintos cortes de cada estudio. Esta decisión resulta adecuada para el problema, ya que una rotura del LCA puede manifestarse únicamente en un número reducido de cortes de la secuencia completa. De este modo, la agregación por máximo permite conservar la señal de anomalía más relevante a lo largo del volumen:

$$y_{\text{pred}} = \max_{i \in \{1, \dots, S\}} \sigma(\mathbf{W}^T f_i + b) \quad (1.1)$$

donde f_i representa el vector de características del corte i extraído por la red convolucional, S es el número total de cortes del volumen, $\mathbf{W}$ y b son los parámetros del clasificador final, y σ representa la función de activación sigmoide.

A partir de esta propuesta inicial, comenzaron a aparecer trabajos que exploraban arquitecturas convolucionales más profundas y eficientes, tales como la familia ResNet [2] o EfficientNet. En general, las redes convolucionales poseen un fuerte **sesgo inductivo** de localidad espacial e invarianza a la traslación, lo que las hace especialmente eficaces para capturar detalles microestructurales como la textura fina, los bordes geométricos y la discontinuidad de las fibras del ligamento en cortes concretos de la imagen.

Sin embargo, debido al campo receptivo limitado de las operaciones de convolución, estos enfoques siguen presentando ciertas restricciones a la hora de modelar relaciones espaciales de largo alcance o de integrar de forma global el contexto tridimensional entre cortes alejados de la articulación.

1.3.3. Vision Transformers (ViT)

La evolución del procesamiento de imágenes condujo posteriormente a la adopción de arquitecturas basadas en *Vision Transformers* (ViT) [3]. El núcleo de estos modelos reside en el mecanismo de autoatención global de múltiples cabezas (*Multi-Head Self-Attention*, MSA), el cual calcula las relaciones mutuas entre parches bidimensionales de la imagen sin depender de filtros locales:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (1.2)$$

donde Q (consultas), K (claves) y V (valores) representan las proyecciones de los parches espaciales de entrada, y d_k es la dimensión de las claves.

La principal ventaja de ViT en la detección de lesiones del LCA es su capacidad para modelar relaciones contextuales globales de larga distancia, permitiendo asociar las características del ligamento con indicios colaterales distribuidos por toda la articulación de la rodilla [4].

No obstante, esta flexibilidad también supone una limitación cuando se trabaja con conjuntos de datos de escala moderada como MRNet. Al carecer del sesgo inductivo de localidad propio de las CNN, un ViT puro requiere grandes volúmenes de datos para aprender por sí mismo la geometría básica de las imágenes, lo que puede favorecer el sobreajuste si no se emplea una inicialización de pesos adecuada o un preentrenamiento robusto en dominios médicos [4].

1.3.4. Swin Transformers

Para abordar los altos requerimientos de datos y el coste computacional cuadrático de la atención global de ViT, surgieron los denominados *Swin Transformers* [5]. Este paradigma introduce una estrategia de autoatención basada en ventanas locales desplazadas (*Shifted Window-based Self-Attention*, SW-MSA) y una topología jerárquica de tipo piramidal.

En lugar de calcular la atención entre todos los parches de la imagen, el Swin Transformer restringe el cómputo de la atención dentro de ventanas locales que no se solapan, reduciendo la complejidad computacional. El desplazamiento de las ventanas en capas consecutivas permite que la información espacial fluya a través de los límites locales y se integre progresivamente.

Simultáneamente, mediante capas de fusión de parches (*Patch Merging*), el modelo construye mapas de características multiescala. Esto resulta especialmente útil para el problema diagnóstico del LCA: las fases tempranas de alta resolución preservan texturas de fibra fina, mientras que las etapas profundas integran una visión más global de la articulación de la rodilla. Esta combinación de propiedades lo convierte en un candidato adecuado para la clasificación directa sin segmentaciones previas.

1.3.5. Comparativa sistemática según protocolo de validación

A partir de la literatura científica revisada, se presenta un análisis detallado del rendimiento de diferentes modelos sobre el dataset MRNet para la detección de roturas del LCA. Con el fin de evitar comparaciones sesgadas o metodológicamente incorrectas, los resultados se han clasificado según el entorno y protocolo de evaluación empleados por cada autor.

Protocolo I: Validación Pública (Tuning Set)

Este protocolo evalúa el rendimiento utilizando como conjunto de test de referencia el Tuning Set oficial de 120 casos de MRNet, cuyas etiquetas son de acceso público para los desarrolladores.

Cuadro 1.2: Resultados bajo el Protocolo I: Validación Pública (Tuning Set de 120 estudios).

Modelo / Autor	Año	Arquitectura principal	Entrada	ROC-AUC	Ref.
MRNet (Bien et al.)	2018	CNN (AlexNet + Max-Pooling)	Axial, Coronal, Sagital	0.957	[1]
VGG-16 Baseline	2020	CNN (VGG-16 estándar)	Sagital única	0.871	[6]
ResNet-50 Baseline	2020	CNN (ResNet-50 estándar)	Sagital única	0.884	[6]
ViT-B/16 Baseline	2021	Vision Transformer (ViT global)	Sagital única	0.892	[4]
Swin-T Baseline	2022	Swin Transformer (ventanas locales)	Sagital única	0.915	[5]
ELNet (Tsai et al.)	2020	CNN optimizada (localización multiescala)	Axial, Coronal, Sagital	0.961	[6]
TransMed (Dai et al.)	2021	Híbrido CNN (ResNet-50) + ViT	Axial, Coronal, Sagital	0.981	[4]
MVANet (Awan et al.)	2022	Híbrido CNN-Transformer + atención	Axial, Coronal, Sagital	0.982	[7]
SGNet (Wang et al.)	2023	CNN + Selective Group Attention	Axial, Coronal, Sagital	0.975	[8]
Azcona et al.	2020	CNN (ResNet-18 + pooling temporal)	Axial, Coronal, Sagital	0.934	[9]
Al Ghothani & Zhang	2023	CNN (ResNet-50 + atención CBAM)	Axial, Coronal, Sagital	0.925	[10]

Protocolo II: Test Oculto Oficial (Hidden Test)

Este protocolo representa el estándar ciego más riguroso de la literatura, ya que las etiquetas reales están retenidas en los servidores de la Universidad de Stanford y la evaluación se realiza de forma remota en la plataforma competitiva oficial.

Cuadro 1.3: Resultados bajo el Protocolo II: Test Oculto Oficial (Hidden Test de 120 estudios).

Modelo / Autor	Año	Arquitectura principal	Entrada	ROC-AUC	Ref.
MRNet (Bien et al.)	2018	CNN (AlexNet + Max-Pooling)	Axial, Coronal, Sagital	0.965	[1]
ELNet (Tsai et al.)	2020	CNN optimizada (localización multiescala)	Axial, Coronal, Sagital	0.959	[6]

Protocolo III: Splits Propios y Validación Cruzada

Este protocolo agrupa los trabajos de autores que reformularon localmente las particiones del dataset original, por ejemplo dividiendo los 1.250 estudios de acceso público en subconjuntos de desarrollo y test propios o aplicando esquemas de validación cruzada.

Cuadro 1.4: Resultados bajo el Protocolo III: Particiones personalizadas de los autores.

Modelo / Autor	Año	Estrategia principal	Protocolo	ROC-AUC	Ref.
Dual-Branch EfficientNet	2021	Fusión de ramas y atención espacial	Split estratificado local 80/20	0.930	[11]
KneeXNet (Joshi et al.)	2023	Red convolucional en grafo (GCN)	Split propio 80/10/10	0.972	[12]
Adapted ResNet-50 (3D)	2022	Operaciones convolucionales 3D	Split propio 70/15/15	0.954	[13]
Adapted ResNet-50 (3D)	2022	Operaciones convolucionales 3D	Validación cruzada de 5 pliegues	0.941	[13]
Weighted Multi-view CNN	2021	Fusión ponderada multivista	Split local 70/10/20	0.928	[14]

1.3.6. Síntesis y posicionamiento del presente trabajo

A partir de la revisión sistemática del estado del arte, pueden extraerse varias conclusiones metodológicas relevantes. En primer lugar, se observa un rendimiento muy competitivo en los modelos híbridos CNN-Transformer, como TransMed, que alcanza 0.981 AUC en validación pública. Este resultado evidencia el beneficio de combinar el sesgo inductivo de localidad propio de las redes convolucionales con la capacidad de los transformers para modelar dependencias globales. Sin embargo, esta mejora suele obtenerse a costa de una mayor complejidad paramétrica y de mayores requisitos computacionales.

Por otra parte, se hace evidente un problema metodológico importante en la literatura: la falta de una comparación directa y homogénea bajo condiciones idénticas de entrenamiento. Muchas publicaciones incorporan técnicas de regularización, módulos atencionales o estrategias de optimización adaptadas específicamente a sus modelos, lo que dificulta determinar si las mejoras de rendimiento se deben realmente a la arquitectura base o a componentes adicionales.

En este marco científico se sitúa el presente Trabajo de Fin de Grado. El objetivo se define como una evaluación comparativa, bajo un mismo entorno de entrenamiento homogéneo, de tres familias arquitectónicas representativas de la evolución reciente en visión por computador: redes convolucionales residuales (**ResNet-50**), transformers globales (**ViT-B/16**) y transformers jerárquicos de ventanas locales (**Swin-T**). Al aislar las variables de optimización y comparar estos tres enfoques de manera equivalente sobre el dataset MRNet, este trabajo busca aportar claridad sobre qué tipo de sesgo arquitectónico resulta más adecuado para el diagnóstico médico automatizado del LCA sin incurrir en costes adicionales de segmentación de imágenes.

Capítulo 2

Materiales

2.1. Conjuntos de datos

En este trabajo se utilizaron dos conjuntos de datos de resonancia magnética de rodilla. El primero fue **MRNet**, empleado como dominio principal para el entrenamiento, validación y prueba interna de los modelos. El segundo fue un conjunto externo procedente de Croacia, utilizado para estudiar la generalización fuera del dominio original y realizar un experimento posterior de adaptación de dominio.

2.1.1. MRNet

MRNet es un dataset público desarrollado por la Escuela de Medicina de la Universidad de Stanford [1]. Contiene estudios de resonancia magnética de rodilla etiquetados para distintas patologías musculoesqueléticas, incluyendo roturas del ligamento cruzado anterior.

Cada estudio está compuesto por tres series tridimensionales correspondientes a los planos anatómicos estándar:

- Plano sagital
- Plano coronal
- Plano axial

Con el objetivo de evitar fuga de información (*data leakage*), las particiones de entrenamiento, validación y prueba se realizaron a nivel de paciente.

Cuadro 2.1: Distribución de casos clínicos empleados en el estudio.

Conjunto	Casos	LCA (+)	Control (-)	Prevalencia
Entrenamiento	875	183	692	20.91 %
Validación	188	36	152	19.15 %
Prueba	187	43	144	22.99 %
Total	1250	262	988	20.96 %

La distribución de clases presenta un desbalance considerable, reflejando una situación representativa del entorno clínico real, donde las lesiones completas del LCA representan una proporción minoritaria respecto al total de estudios de RM de rodilla.

2.1.2. Conjunto externo de Croacia

Además de MRNet, se utilizó un conjunto externo de resonancias magnéticas de rodilla procedente de Croacia. Este dataset permitió evaluar la robustez de los modelos ante un cambio de dominio, es decir, ante posibles diferencias en población, protocolo de adquisición, escáner o distribución de las imágenes respecto al conjunto original.

El conjunto de Croacia contiene 917 estudios, de los cuales 690 corresponden a casos sin rotura del LCA y 227 a casos con rotura. En primer lugar, se empleó para una validación externa *zero-shot*, evaluando los modelos entrenados sobre MRNet sin reajustar sus pesos. Posteriormente, se utilizó para un experimento de *fine-tuning* con el objetivo de analizar si la adaptación al nuevo dominio podía mejorar el rendimiento o modificar la calibración del clasificador.

Para el experimento de adaptación de dominio, el conjunto de Croacia se dividió en 641 casos de entrenamiento, 138 de validación y 138 de prueba. En el subconjunto de prueba había 104 casos sin rotura y 34 casos con rotura del LCA. Igual que en MRNet, las particiones se realizaron a nivel de paciente para evitar fuga de información entre conjuntos.

2.2. Representación y preprocesamiento de datos

Cada estudio de RM puede representarse matemáticamente como un volumen tridimensional:

$$V \in \mathbb{R}^{S \times H \times W} \quad (2.1)$$

donde S representa el número de cortes del volumen, mientras que H y W corresponden a la resolución espacial de cada corte.

Las intensidades de píxel fueron normalizadas mediante escalado Min-Max:

$$x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (2.2)$$

Posteriormente, todas las imágenes fueron redimensionadas a una resolución espacial de 224×224 píxeles. Dado que los modelos empleados utilizan pesos preentrenados en ImageNet, las imágenes monocanal fueron replicadas sobre tres canales de entrada.

Capítulo 3

Métodos

3.1. Descripción general del sistema

El objetivo principal de este trabajo consiste en desarrollar un sistema de aprendizaje profundo capaz de detectar automáticamente lesiones del ligamento cruzado anterior (LCA) a partir de estudios de resonancia magnética (RM) de rodilla.

La metodología propuesta sigue un enfoque de clasificación directa de extremo a extremo (*end-to-end*), evitando etapas explícitas de segmentación anatómica. Esta decisión se fundamenta tanto en criterios prácticos como clínicos. Por una parte, los modelos de segmentación requieren máscaras anotadas manualmente por especialistas, lo que supone un elevado coste temporal y computacional. Por otra, la clasificación directa permite preservar información contextual relevante de toda la articulación, incluyendo signos indirectos de lesión.

El pipeline general desarrollado puede dividirse en las siguientes etapas:

1. Carga y normalización de estudios de resonancia magnética.
2. Selección automática de cortes anatómicamente relevantes.
3. Extracción de características mediante arquitecturas CNN y Transformer.
4. Agregación de información entre cortes utilizando mecanismos de atención.
5. Fusión multi-vista entre planos anatómicos.
6. Clasificación binaria de lesión del LCA.

3.2. Selección automática de cortes anatómicos

Uno de los principales problemas asociados al procesamiento completo de volúmenes de RM es que únicamente una fracción reducida de los cortes contiene información anatómica relevante sobre el ligamento cruzado anterior.

Procesar todos los cortes incrementa:

- el ruido visual,

- el coste computacional,
- y la redundancia espacial.

Por este motivo, en este trabajo se desarrolló un módulo propio de selección automática de cortes basado en una arquitectura **MobileNetV3**. En concreto, se entrenaron dos modelos independientes: uno específico para el plano sagital y otro específico para el plano coronal. Cada uno de ellos fue entrenado con sus propias etiquetas de relevancia anatómica, generadas de forma independiente para el plano correspondiente, de modo que el selector aprendiera qué cortes eran más informativos dentro de cada orientación.

La idea principal consiste en procesar los N cortes que componen una serie de resonancia magnética y asignar a cada uno de ellos una puntuación de probabilidad asociada a la presencia o visibilidad del LCA en la imagen. A partir de estas puntuaciones, el sistema ordena los cortes de mayor a menor relevancia anatómica y selecciona automáticamente los K cortes más informativos para el clasificador final.

De este modo, para cada estudio de RM el módulo actúa como una etapa previa de filtrado: recibe una secuencia completa de cortes sagitales o coronales y devuelve únicamente los 5 o 10 cortes con mayor probabilidad de contener información útil sobre el LCA, según el plano anatómico considerado. Esta selección no pretende diagnosticar la lesión, sino localizar las imágenes donde el ligamento es más visible o donde es más probable que aparezca información anatómica relevante para la clasificación posterior.

Esta estrategia se plantea como una contribución metodológica específica del trabajo. En lugar de utilizar únicamente cortes centrales o procesar todo el volumen completo, se introduce un selector aprendido que reduce la redundancia, limita el ruido visual y concentra el entrenamiento de los modelos diagnósticos en las regiones más relevantes. Hasta donde se ha revisado en el desarrollo de este trabajo, no se ha identificado una estrategia equivalente aplicada de esta forma en los trabajos comparados.

3.2.1. Estrategias evaluadas

Se analizaron distintas estrategias de selección:

- **Center**: selección geométrica de los cortes centrales del volumen.
- **Random**: selección aleatoria utilizada durante entrenamiento como mecanismo de regularización.
- **CNN-Based**: selección automática basada en las puntuaciones generadas por MobileNetV3.

La configuración final utilizada fue:

- Plano sagital: $K = 5$ cortes mediante estrategia *CNN-Based*.
- Plano coronal: $K = 10$ cortes mediante estrategia *CNN-Based*.
- Plano axial: $K = 10$ cortes centrales consecutivos.

3.3. Arquitecturas de aprendizaje profundo

Con el objetivo de comparar distintos paradigmas de visión por computador, se seleccionaron arquitecturas representativas tanto de redes convolucionales como de Vision Transformers.

Cuadro 3.1: Arquitecturas de aprendizaje profundo evaluadas en el estudio.

Modelo	Familia	Parámetros
ResNet50	CNN residual	23.5 M
ViT-Base	Transformer global	86.0 M
Swin-Small	Transformer jerárquico	49.6 M

3.4. Redes Convolucionales

3.4.1. ResNet50

El modelo *Residual Network 50* (ResNet50) [2] representa la arquitectura convolucional profunda utilizada como línea base en este trabajo. Esta arquitectura se fundamenta en el uso de conexiones residuales (*skip connections*) que permiten facilitar la propagación del gradiente a través de las capas profundas:

$$y = \mathcal{F}(x, \{W_i\}) + x \quad (3.1)$$

donde x e y representan los vectores de entrada y salida del bloque residual, mientras que $\mathcal{F}$ corresponde al mapeo residual aprendido por las capas convolucionales.

A diferencia de los modelos basados en Transformers, las redes convolucionales explotan de forma natural los sesgos inductivos de localidad espacial e invarianza a la traslación mediante el uso de filtros convolucionales compartidos. Esta propiedad las hace especialmente eficaces para detectar:

- texturas locales,
- discontinuidades anatómicas,
- y patrones geométricos finos presentes en las fibras ligamentarias.

Adaptación al análisis volumétrico

La configuración utilizada corresponde a la arquitectura ResNet50 preentrenada sobre ImageNet-1K, compuesta por aproximadamente 23.5 millones de parámetros.

Dado que ResNet50 está diseñada originalmente para imágenes bidimensionales, se aplicó la estrategia multi-corte descrita anteriormente. Cada corte seleccionado se procesó individualmente mediante el backbone convolucional y sus representaciones se agregaron según el plano anatómico:

- **Plano sagital:** agregación mediante *Attention Pooling*.
- **Plano coronal:** agregación mediante *Max Pooling*.
- **Plano axial:** agregación mediante *Attention Pooling*.

Entrenamiento y optimización

El entrenamiento de ResNet50 se realizó utilizando el optimizador **AdamW**, junto con estrategias de planificación dinámica de la tasa de aprendizaje y regularización adaptadas al problema médico.

La optimización se llevó a cabo mediante un esquema de reducción por meseta (*ReduceLROnPlateau*), reduciendo dinámicamente la tasa de aprendizaje cuando la pérdida de validación dejaba de mejorar durante varias épocas consecutivas.

Adicionalmente, se empleó una fase inicial de calentamiento progresivo (*warmup*) para estabilizar el entrenamiento durante las primeras épocas.

Con el objetivo de mejorar la estabilidad numérica y evitar oscilaciones bruscas en la optimización, se aplicó recorte de gradientes (*Gradient Clipping*) sobre determinados planos anatómicos.

Estrategias de regularización

Dado que las redes convolucionales pueden presentar una elevada capacidad de memorización sobre conjuntos de datos médicos de tamaño moderado, se aplicaron distintas estrategias de regularización para reducir el riesgo de sobreajuste:

- **Dropout:** aplicado tanto sobre las capas de entrada como sobre el clasificador final.
- **Label Smoothing:** utilizado para suavizar las etiquetas y evitar predicciones excesivamente rígidas.
- **Early Stopping:** monitorizando el AUC sobre validación para detener el entrenamiento cuando no se observaban mejoras relevantes.

Cuadro 3.2: Parámetros de regularización utilizados durante el entrenamiento de ResNet50.

Plano	Dropout Input	Dropout Dense	Label Smoothing	Early Stopping
Sagital	0.42	0.32	0.17	12 épocas
Coronal	0.47	0.37	0.22	10 épocas
Axial	0.42	0.32	0.17	12 épocas

3.5. Vision Transformers

3.5.1. ViT-Base

El modelo *Vision Transformer Base* (ViT-Base) [3] reemplaza las convoluciones tradicionales por mecanismos de autoatención global. La imagen de entrada se divide inicialmente en pequeños parches bidimensionales:

$$x \rightarrow \{p_1, p_2, \dots, p_n\} \quad (3.2)$$

Cada parche es proyectado posteriormente a un espacio de embeddings y procesado mediante bloques Transformer. El mecanismo de atención se calcula como:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (3.3)$$

donde Q , K y V representan las matrices de consultas, claves y valores.

A diferencia de las redes convolucionales, ViT-Base permite modelar relaciones espaciales globales entre regiones anatómicas alejadas de la imagen mediante mecanismos de autoatención multi-cabeza (*Multi-Head Self-Attention*, MHSA).

Adaptación al análisis volumétrico

La configuración utilizada en este trabajo corresponde al modelo preentrenado ViT-Base Patch16-224, compuesto por:

- 12 bloques Transformer,
- dimensión de embedding de 768,
- 12 cabezas de atención,
- y aproximadamente 86 millones de parámetros.

Dado que ViT-Base está diseñado originalmente para imágenes bidimensionales, se aplicó la misma estrategia multi-corte por plano anatómico. Cada corte seleccionado fue procesado por el backbone Transformer para obtener un vector de características de dimensión $D = 768$, y la agregación final se realizó de la siguiente forma:

- **Plano sagital:** agregación mediante *Attention Pooling*.
- **Plano coronal:** agregación mediante *Max Pooling*.
- **Plano axial:** agregación mediante *Attention Pooling*.

Entrenamiento y optimización

El entrenamiento de ViT-Base se realizó utilizando el optimizador **AdamW**, con una tasa de aprendizaje máxima de:

$$\eta_{\max} = 1,5 \times 10^{-4} \quad (3.4)$$

Para estabilizar el entrenamiento se empleó una estrategia de calentamiento inicial (*warmup*) seguida de un decaimiento tipo *Cosine Annealing*.

Además, se aplicaron distintas técnicas de regularización con el objetivo de reducir el sobreajuste asociado a la elevada complejidad paramétrica del modelo:

- **Dropout**: aplicado tanto sobre las capas de entrada como sobre el clasificador final.
- **Label Smoothing**: utilizado para evitar predicciones excesivamente confiadas.
- **Gradient Clipping**: empleado para estabilizar la optimización en determinados planos anatómicos.
- **Early Stopping**: monitorizando el AUC sobre validación.

Cuadro 3.3: Parámetros de regularización utilizados durante el entrenamiento de ViT-Base.

Plano	Dropout Input	Dropout Dense	Label Smoothing	Early Stopping
Sagital	0.30	0.20	0.05	25 épocas
Coronal	0.35	0.25	0.05	15 épocas
Axial	0.35	0.25	0.10	15 épocas

3.6. Swin Transformers

3.6.1. Swin-Small

El modelo *Shifted Window Transformer Small* (Swin-Small) [5] representa una evolución jerárquica de los Vision Transformers basada en mecanismos de atención local mediante ventanas desplazadas (*Shifted Window Self-Attention*).

A diferencia de Vision Transformer (ViT), donde la atención se calcula globalmente entre todos los parches de la imagen, Swin Transformer restringe el cálculo de atención a ventanas locales no solapadas, reduciendo significativamente la complejidad computacional.

El mecanismo de atención puede expresarse como:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} + B \right) V \quad (3.5)$$

donde B representa una matriz de sesgo de posición relativa que codifica la distancia espacial entre los parches dentro de cada ventana.

Mediante la estrategia de ventanas desplazadas, el modelo permite el intercambio progresivo de información contextual entre regiones vecinas de la imagen, combinando eficiencia computacional y capacidad de representación multiescala.

Adaptación al análisis volumétrico

La configuración utilizada corresponde al modelo Swin-Small preentrenado sobre ImageNet-1K. Esta arquitectura procesa inicialmente parches de 4×4 píxeles y construye representaciones jerárquicas mediante operaciones de *Patch Merging* a lo largo de distintas etapas profundas.

La variante empleada en este trabajo contiene aproximadamente 49.7 millones de parámetros.

Para adaptar el modelo al análisis volumétrico de resonancia magnética, se aplicó la estrategia multi-corte por plano anatómico. A diferencia de las restantes arquitecturas evaluadas, Swin-Small se configuró utilizando imágenes de entrada de mayor resolución espacial (256×256 píxeles), con el objetivo de preservar detalles anatómicos finos relacionados con la morfología ligamentaria. La agregación se realizó de la siguiente forma:

- **Plano sagital:** agregación mediante *Attention Pooling*.
- **Plano coronal:** agregación mediante *Attention Pooling*.
- **Plano axial:** agregación mediante *Attention Pooling*.

Entrenamiento y optimización

El entrenamiento de Swin-Small se realizó utilizando el optimizador **AdamW**, junto con estrategias específicas de planificación de la tasa de aprendizaje y regularización.

Debido a la elevada capacidad representacional del modelo y a las diferencias de estabilidad durante el entrenamiento entre los distintos planos anatómicos, se empleó un programador dinámico de tasa de aprendizaje de tipo *ReduceLROnPlateau* junto con recorte de gradientes (*Gradient Clipping*) para mejorar la estabilidad del entrenamiento.

La planificación de la tasa de aprendizaje se realizó mediante una combinación de:

- tasa de aprendizaje inicial de $1,3 \times 10^{-4}$,
- planificación dinámica adaptativa tipo *ReduceLROnPlateau* con factor de reducción de 0,5 y paciencia personalizada,
- y recorte de gradientes (*Gradient Clipping*) con norma límite de 1,0.

Estrategias de regularización

Los parámetros de regularización fueron ajustados de forma independiente según las características y sensibilidad al sobreajuste de cada plano anatómico:

- **Dropout:** aplicado tanto sobre la proyección de entrada del clasificador (*dropout input*) como en las capas densas (*dropout dense*).

- **Label Smoothing:** utilizado para suavizar las etiquetas de entrenamiento y evitar predicciones excesivamente confiadas.
- **Early Stopping:** monitorizando la métrica AUC sobre el conjunto de validación para prevenir el sobreajuste de la red.

Las estrategias de regularización se ajustaron de forma independiente según las características anatómicas de cada plano. En el plano axial, el factor de *dropout input* se estableció en un valor de 0.00 con el objetivo de preservar las características visuales finas asociadas a la representación transversal del LCA. Por el contrario, los planos sagital y coronal emplearon niveles de regularización más elevados debido a la mayor redundancia anatómica presente en dichos cortes.

Cuadro 3.4: Parámetros de regularización utilizados durante el entrenamiento de Swin-Small.

Plano	Dropout Input	Dropout Dense	Label Smoothing	Early Stopping
Sagital	0.42	0.32	0.17	12 épocas
Coronal	0.42	0.32	0.17	40 épocas
Axial	0.00	0.20	0.05	30 épocas

Capítulo 4

Resultados y Discusión

4.0.1. Diseño experimental y criterios de evaluación clínica

El objetivo de los experimentos fue evaluar la capacidad de distintas arquitecturas de aprendizaje profundo para detectar roturas del ligamento cruzado anterior (LCA) en estudios de resonancia magnética de rodilla. Para ello, se compararon tres familias de modelos: una red convolucional residual, *ResNet50*; un transformer global, *Vision Transformer Base* (ViT-Base); y un transformer jerárquico basado en ventanas desplazadas, *Swin Transformer Small*.

El entrenamiento se organizó por planos anatómicos. Se entrenaron modelos independientes para las proyecciones sagital, coronal y axial y, posteriormente, se integraron sus salidas probabilísticas en un ensamble multi-vista. Además, para cada arquitectura y plano anatómico se utilizaron diez semillas independientes, comprendidas entre la 42 y la 51, con el fin de cuantificar la estabilidad del entrenamiento.

La métrica prioritaria fue la sensibilidad o *recall*, ya que un falso negativo implica no detectar una lesión real. Por ello, el umbral de decisión se seleccionó en validación maximizando la sensibilidad bajo una precisión mínima de 0.75:

$$\tau^* = \arg \max_{\tau} \text{Recall}(\tau) \quad \text{sujeto a} \quad \text{Precision}(\tau) \geq 0.75. \quad (4.1)$$

La calibración del umbral se realizó exclusivamente sobre validación; el conjunto de test se utilizó solo para estimar el rendimiento final bajo el punto operativo seleccionado.

La combinación multi-vista se realizó mediante el promedio simple de las probabilidades obtenidas por los tres modelos especializados por plano:

$$\hat{p}_{\text{ens}} = \frac{\hat{p}_{\text{sagital}} + \hat{p}_{\text{coronal}} + \hat{p}_{\text{axial}}}{3}. \quad (4.2)$$

Este esquema de fusión no introduce parámetros adicionales y permite comparar directamente el rendimiento de modelos individuales y multi-vista.

Hiperparámetros relevantes del entrenamiento

En los experimentos multi-semilla se emplearon aumentos de datos, *dropout*, suavizado de etiquetas cuando correspondía y *early stopping* con paciencia máxima de 25 épocas.

El experimento de adaptación de dominio se realizó con el conjunto externo de Croacia descrito en el capítulo de materiales. En este caso, se ajustó el modelo Swin-Small sagital con una tasa de aprendizaje inicial de 2×10^{-4} , pérdida BCE ponderada con `pos_weight` = 3.0314, *dropout* de 0.3 en la entrada del clasificador y *dropout* de 0.2 en la capa densa final.

4.0.2. Resultados del modelo convolucional ResNet50

La arquitectura convolucional *ResNet50* se utilizó como referencia frente a los modelos basados en transformers.

Análisis de estabilidad multi-semilla

La Tabla 4.1 resume la estabilidad multi-semilla de ResNet50.

Cuadro 4.1: Análisis de estabilidad multi-semilla para la arquitectura ResNet50.

Plano	AUC medio	Desv. est.	AUC mín.	AUC máx.	Mejor semilla
Sagital	0.9425	0.0170	0.9132	0.9638	46
Coronal	0.9390	0.0169	0.8973	0.9638	44
Axial	0.9610	0.0087	0.9501	0.9810	51

El plano axial presentó simultáneamente el mayor AUC medio y la menor desviación estándar en validación, lo que indica un comportamiento particularmente estable. Los planos sagital y coronal también mostraron valores medios elevados, aunque con una variabilidad mayor entre ejecuciones. Esta diferencia refuerza la utilidad del análisis multi-semilla: una única ejecución podría sobreestimar o subestimar el rendimiento real de la arquitectura.

La Figura 4.1 muestra la evolución del entrenamiento multi-semilla de ResNet50 en los tres planos anatómicos.




Figura 4.1: Evolución del entrenamiento multi-semilla de ResNet50 en los planos sagital, coronal y axial.

Rendimiento de los modelos fijados por validación por plano anatómico

Tras el análisis multi-semilla, se fijó un checkpoint por plano anatómico utilizando únicamente el comportamiento observado en validación. El conjunto de test se empleó después solo como evaluación final. Estos resultados se resumen en la Tabla 4.2.

Cuadro 4.2: Rendimiento de los modelos ResNet50 fijados por plano anatómico utilizando únicamente validación.

Plano anatómico	AUC validación	AUC test
Sagital	0.9501	0.8679
Coronal	0.9735	0.9246
Axial	0.9704	0.9294

En la evaluación final sobre test, el plano sagital obtuvo el menor rendimiento individual, mientras que el axial alcanzó el mayor AUC. Esta observación se reporta únicamente como resultado final, no como criterio de selección.

La Figura 4.2 recoge las curvas de entrenamiento de los checkpoints finalmente fijados por validación para cada plano.




Figura 4.2: Curvas de entrenamiento de los mejores checkpoints de ResNet50 por plano anatómico.

Ensamble multi-vista calibrado

El ensamble ResNet50 utilizó un umbral calibrado en validación de $\tau = 0,5445$. Sus métricas principales se recogen en la Tabla 4.3.

Cuadro 4.3: Rendimiento del ensamble multi-vista basado en ResNet50 con umbral calibrado en validación.

Conjunto	AUC	Acc	Prec.	Recall	Esp.	F1	Umbral
Validación	0.9836	0.9362	0.7609	0.9722	0.9276	0.8537	0.5445
Test	0.9545	0.8556	0.6333	0.8837	0.8472	0.7379	0.5445

Cuadro 4.4: Matriz de confusión del ensamble ResNet50.

Conjunto	VP	FN	FP	VN
Validación	35	1	11	141
Test	38	5	22	122

En la evaluación final sobre test de MRNet, el ensamble ResNet50 alcanzó un AUC de 0.9545. Su sensibilidad fue ligeramente inferior a la obtenida por Swin-Small: ResNet50 dejó 5 falsos negativos en test, frente a los 4 falsos negativos del ensamble Swin-Small. Estos resultados se interpretan de forma descriptiva, sin utilizarlos para reajustar el modelo.

4.0.3. Resultados del modelo Vision Transformer (ViT-Base)

Vision Transformer Base (ViT-Base) procesa la imagen como una secuencia de parches y emplea autoatención global.

Análisis de estabilidad multi-semilla

La Tabla 4.5 presenta el análisis multi-semilla de ViT-Base para las diez semillas evaluadas.

Cuadro 4.5: Análisis de estabilidad multi-semilla para la arquitectura ViT-Base.

Plano	AUC medio	Desv. est.	AUC mín.	AUC máx.	Mejor semilla
Sagital	0.9548	0.0068	0.9433	0.9633	47
Coronal	0.8923	0.0355	0.8419	0.9435	50
Axial	0.9570	0.0130	0.9327	0.9720	43

El análisis multi-semilla evidencia una diferencia importante entre planos. El plano sagital fue el más estable, con una desviación estándar de 0.0068, mientras que el plano coronal presentó una variabilidad claramente superior. Esta inestabilidad puede explicarse por la dificultad de localizar de forma consistente el LCA en dicha proyección, donde la estructura puede aparecer parcialmente representada y con mayor interferencia de tejidos circundantes.

La sensibilidad de ViT-Base a la inicialización es coherente con la naturaleza de los transformers globales. Al no incorporar de forma explícita el sesgo inductivo de localización espacial característico de las redes convolucionales, el modelo debe aprender durante el entrenamiento qué relaciones entre parches son relevantes. Esta flexibilidad puede ser beneficiosa cuando la convergencia es adecuada, pero también puede incrementar la variabilidad en conjuntos médicos de tamaño moderado.

La Figura 4.3 muestra la evolución del entrenamiento multi-semilla de ViT-Base en los tres planos anatómicos.




Figura 4.3: Evolución del entrenamiento multi-semilla de ViT-Base en los planos sagital, coronal y axial.

Rendimiento de los modelos fijados por validación por plano anatómico

Tras el análisis multi-semilla, se fijó un modelo por plano utilizando únicamente la información de validación. Posteriormente, el conjunto de test se utilizó solo para estimar el rendimiento final. Los resultados se muestran en la Tabla 4.6.

Cuadro 4.6: Rendimiento de los modelos ViT-Base fijados por plano anatómico utilizando únicamente validación.

Plano anatómico	AUC validación	AUC test
Sagital	0.9534	0.9031
Coronal	0.9346	0.9233
Axial	0.9755	0.9075

Los modelos fijados de ViT-Base alcanzaron un rendimiento competitivo en los tres planos. En validación destacó el plano axial, mientras que las métricas de test se reportan exclusivamente como evaluación final.

Ensamble multi-vista calibrado

El ensamble ViT-Base utilizó un umbral de $\tau = 0,5135$, seleccionado en validación. La Tabla 4.7 resume las métricas principales.

Cuadro 4.7: Rendimiento del ensamble multi-vista basado en ViT-Base con umbral calibrado en validación.

Conjunto	AUC	Acc	Prec.	Recall	Esp.	F1	Umbral
Validación	0.9834	0.9309	0.7556	0.9444	0.9276	0.8395	0.5135
Test	0.9364	0.8717	0.6727	0.8605	0.8750	0.7551	0.5135

Cuadro 4.8: Matriz de confusión del ensamble ViT-Base.

Conjunto	VP	FN	FP	VN
Validación	34	2	11	141
Test	37	6	18	126

En la evaluación final sobre test, ViT-Base mostró mayor exactitud, precisión, especificidad y F1-score que los otros ensambles, aunque también menor sensibilidad, con 6 falsos negativos.

La Figura 4.4 resume las curvas de mejores checkpoints de ViT-Base.




Figura 4.4: Curvas de entrenamiento de los mejores checkpoints de ViT-Base por plano anatómico.

4.0.4. Resultados del modelo Swin Transformer Small

Swin Transformer Small combina atención local mediante ventanas desplazadas con una representación jerárquica.

Análisis de estabilidad multi-semilla

Al igual que en ResNet50 y ViT-Base, Swin-Small fue evaluado mediante diez semillas independientes por plano anatómico. La Tabla 4.9 resume los resultados de validación por plano.

Cuadro 4.9: Análisis de estabilidad multi-semilla para la arquitectura Swin-Small.

Plano	AUC medio	Desv. est.	AUC mín.	AUC máx.
Sagital	0.9223	0.0787	0.7004	0.9649
Coronal	0.7748	0.1348	0.5970	0.9684
Axial	0.9560	0.0123	0.9368	0.9722

El plano axial fue el más estable, con un AUC medio de 0.9560 y una desviación estándar de 0.0123. En cambio, el plano coronal mostró la mayor variabilidad.

Esta variabilidad impide afirmar que Swin-Small sea el modelo más estable en todos los planos individuales. Por este motivo, su interpretación debe basarse en el conjunto de evidencias: estabilidad en validación, comportamiento del ensamble y evaluación externa. Las métricas de test y de Croacia se presentan como estimaciones finales de rendimiento, no como criterios para escoger o reajustar el modelo.

La Figura 4.5 muestra la evolución del entrenamiento multi-semilla de Swin-Small en los tres planos anatómicos.




Figura 4.5: Evolución del entrenamiento multi-semilla de Swin-Small en los planos sagital, coronal y axial.

Selección de modelos para el ensamble

A partir del análisis multi-semilla se fijaron los checkpoints utilizados en cada plano anatómico para construir el ensamble, empleando únicamente información procedente de validación. De este modo, las métricas del ensamble no se presentan como una ejecución aislada, sino como el resultado de combinar modelos definidos antes de consultar el conjunto de test.

La Figura 4.6 recoge las curvas de entrenamiento de los checkpoints seleccionados para Swin-Small.




Figura 4.6: Curvas de entrenamiento de los mejores checkpoints de Swin-Small por plano anatómico.

Ensamble multi-vista calibrado

El ensamble Swin-Small se construyó mediante promedio simple de las probabilidades de los tres planos. El umbral seleccionado en validación fue $\tau = 0,3734$. Las métricas se presentan en la Tabla 4.10.

Cuadro 4.10: Rendimiento del ensamble multi-vista basado en Swin-Small con umbral calibrado en validación.

Conjunto	AUC	Acc	Prec.	Recall	Esp.	F1	Umbral
Validación	0.9837	0.9362	0.7609	0.9722	0.9276	0.8537	0.3734
Test	0.9536	0.8556	0.6290	0.9070	0.8403	0.7429	0.3734

Cuadro 4.11: Matriz de confusión del ensamble Swin-Small.

Conjunto	VP	FN	FP	VN
Validación	35	1	11	141
Test	39	4	23	121

En la evaluación final sobre test, Swin-Small obtuvo una sensibilidad de 0.9070, detectando 39 de las 43 roturas presentes y dejando 4 falsos negativos. El coste de este punto operativo fue un aumento de los falsos positivos, con 23 controles clasificados como positivos, lo que redujo su precisión y especificidad respecto a ViT-Base.

Desde una perspectiva clínica, este comportamiento puede ser favorable cuando se prioriza la reducción de falsos negativos. Sin embargo, no debe interpretarse como una mejora universal en todas las métricas ni como una elección definitiva basada en test.

4.0.5. Comparativa final de ensambles en MRNet

La comparación entre ensambles debe interpretarse separando dos niveles. En primer lugar, la Tabla 4.12 resume el rendimiento en validación, que es el conjunto utilizado para fijar los umbrales y describir el comportamiento operativo esperado. En segundo lugar, la Tabla 4.13 muestra la evaluación final sobre el conjunto de test de MRNet, utilizado únicamente para estimar la capacidad de generalización bajo las decisiones previamente fijadas.

Esta comparación permite distinguir entre rendimiento discriminativo global, medido mediante AUC, y rendimiento clínico bajo el umbral seleccionado, medido mediante sensibilidad, especificidad, precisión y F1-score.

Cuadro 4.12: Comparativa de los ensambles multi-vista en el conjunto de validación de MRNet.

Modelo	AUC	Acc	Prec.	Recall	Esp.	F1	FN	FP
ViT-Base	0.9834	0.9309	0.7556	0.9444	0.9276	0.8395	2	11
ResNet50	0.9836	0.9362	0.7609	0.9722	0.9276	0.8537	1	11
Swin-Small	0.9837	0.9362	0.7609	0.9722	0.9276	0.8537	1	11

Cuadro 4.13: Comparativa de los ensambles multi-vista en el conjunto de test de MRNet.

Modelo	AUC	Acc	Prec.	Recall	Esp.	F1	FN	FP
ViT-Base	0.9364	0.8717	0.6727	0.8605	0.8750	0.7551	6	18
ResNet50	0.9545	0.8556	0.6333	0.8837	0.8472	0.7379	5	22
Swin-Small	0.9536	0.8556	0.6290	0.9070	0.8403	0.7429	4	23

En validación, ResNet50 y Swin-Small obtuvieron el mismo punto operativo bajo el criterio clínico definido, con un falso negativo y once falsos positivos, mientras que Swin-Small alcanzó un AUC ligeramente superior. En test, ResNet50 obtuvo el mayor AUC, ViT-Base mostró mayor exactitud, precisión, especificidad y F1-score, y Swin-Small alcanzó la mayor sensibilidad. Estas diferencias se reportan como evaluación final bajo criterios definidos previamente en validación.

La Figura 4.7 agrupa las curvas ROC de validación de los tres ensambles. La Figura 4.8 muestra las curvas ROC de test disponibles para ResNet50 y Swin-Small en MRNet.




Figura 4.7: Curvas ROC de validación de los ensambles ResNet50, ViT-Base y Swin-Small en MRNet.




Figura 4.8: Curvas ROC de test disponibles para los ensambles ResNet50 y Swin-Small en MRNet.

En consecuencia, no se propone una selección definitiva de un único modelo a partir del conjunto de test. La comparación en validación permite justificar el comportamiento operativo sin usar test para tomar decisiones, mientras que la comparación en test permite describir compromisos finales entre discriminación global, sensibilidad y falsos positivos.

4.0.6. Validación externa zero-shot en el conjunto de datos de Croacia

La generalización externa se evaluó en el conjunto de Croacia descrito en el capítulo de materiales. La evaluación se realizó en el plano sagital y sin entrenamiento adicional, por lo que corresponde a un escenario *zero-shot*.

Las métricas principales se presentan en la Tabla 4.14 y las matrices de confusión correspondientes en la Tabla 4.15.

Cuadro 4.14: Validación externa zero-shot en el conjunto de datos de Croacia.

Modelo	AUC	Acc	Prec.	Recall	Esp.	F1
ResNet50	0.7847	0.8702	0.8699	0.5595	0.9725	0.6810
ViT-Base	0.8387	0.8626	0.7590	0.6520	0.9319	0.7014
Swin-Small	0.8821	0.8659	0.8377	0.5683	0.9638	0.6772

Cuadro 4.15: Matrices de confusión en la validación externa de Croacia.

Modelo	VP	FN	FP	VN
ResNet50	127	100	19	671
ViT-Base	148	79	47	643
Swin-Small	129	98	25	665

Los resultados evidencian un cambio de dominio relevante entre MRNet y el conjunto de Croacia. Todos los modelos reducen su sensibilidad en la validación externa, lo que indica que las diferencias de adquisición, población, escáner o protocolo pueden afectar al punto operativo aprendido en el dominio original.

En la evaluación externa, Swin-Small obtuvo el mayor AUC, con 0.8821, mientras que ViT-Base alcanzó la mayor sensibilidad, con 0.6520. Estos resultados se interpretan como una estimación de generalización externa y no como un criterio de reajuste posterior.

4.0.7. Adaptación de dominio mediante fine-tuning en Croacia

Para analizar la adaptación al nuevo dominio, se realizó *fine-tuning* sobre el conjunto de Croacia.

El modelo utilizado para este experimento fue Swin-Small en el plano sagital. La configuración de entrenamiento incluyó una tasa de aprendizaje inicial de 2×10^{-4} , pérdida BCE con `pos_weight = 3.0314` para compensar el desbalance de clases, *dropout* de 0.3 en la entrada del clasificador y *dropout* de 0.2 en la capa densa final. Durante las dos primeras épocas se mantuvo congelado el *backbone*, entrenando únicamente la cabecera clasificadora. A partir de la tercera época se realizó ajuste completo de los pesos del modelo, con reducción de la tasa de aprendizaje en caso de estancamiento.

Una vez realizada la validación externa *zero-shot* sobre el conjunto completo de Croacia, se creó una partición específica de entrenamiento, validación y prueba para adaptar el modelo al nuevo dominio. El rendimiento antes y después del ajuste se evaluó sobre el subconjunto de prueba de Croacia, no sobre MRNet. Los resultados principales se muestran en la Tabla 4.16.

Cuadro 4.16: Evaluación del modelo Swin-Small sagital sobre el test de Croacia antes y después del fine-tuning.

Evaluación en Croacia test	AUC
Antes del fine-tuning	0.9236
Después del fine-tuning	0.9362
Diferencia	+0.0126

Tras el *fine-tuning*, el AUC sobre el test de Croacia aumentó de 0.9236 a 0.9362. Por tanto, el ajuste con datos del nuevo dominio produjo una mejora moderada en la capacidad discriminativa del modelo sagital. Esta comparación debe interpretarse separadamente de la validación *zero-shot* anterior: primero se evaluó la transferencia directa sobre Croacia sin entrenamiento adicional y, posteriormente, se evaluó el efecto de adaptar el modelo utilizando las particiones de entrenamiento y validación de Croacia.

Las curvas asociadas al ajuste fino no se incorporan como figuras principales porque la conclusión relevante queda resumida por la comparación antes/después del AUC. Su función es comprobar la dinámica de entrenamiento y la ausencia de inestabilidades evidentes, por lo que se consideran material complementario.

4.0.8. Discusión general de los resultados

Los experimentos muestran, en primer lugar, que el análisis multi-semilla es necesario en datasets médicos de tamaño moderado, ya que la inicialización puede afectar al rendimiento final. También confirman la utilidad de integrar información multi-vista: las tres arquitecturas obtuvieron resultados competitivos al combinar las probabilidades de los planos sagital, coronal y axial.

La comparación de ensambles en MRNet no identifica un ganador absoluto. Cada arquitectura mostró compromisos distintos entre AUC, sensibilidad, precisión y especificidad. Dado el coste clínico de los falsos negativos, los modelos con mayor sensibilidad pueden ser especialmente interesantes como herramientas de cribado, aunque un mayor número de falsos positivos obliga a interpretar sus predicciones como apoyo y no como sustituto de la evaluación radiológica.

Finalmente, la validación externa en Croacia evidencia *domain shift*: Swin-Small obtuvo el mayor AUC externo, pero la sensibilidad disminuyó respecto al test interno. El *fine-tuning* sobre Croacia mejoró el AUC en el subconjunto de prueba de ese mismo dominio, aunque la calibración del punto operativo sigue siendo un aspecto crítico. En conjunto, los resultados apoyan el uso de ensambles multi-vista y refuerzan la necesidad de validación externa, calibración multi-centro y ajuste de umbrales específicos por dominio clínico.

Capítulo 5

Conclusiones (obligatorio) y proyección futura.

5.1. Conclusiones

5.2. Trabajo futuro

Bibliografía

- [1] N. Bien, P. Rajpurkar, N. P. Schrager, et al. Deep-learning-assisted diagnosis for knee magnetic resonance imaging: Development and retrospective validation of mrnet. *PLOS Medicine*, 15(11):e1002699, 2018.
- [2] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, 2016.
- [3] A. Dosovitskiy et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [4] Y. Dai et al. Transmed: Transformers meet select-convolutions for multi-modal medical image classification. *Biosensors*, 11(11):443, 2021.
- [5] Z. Liu et al. Swin transformer: Hierarchical vision transformer using shifted windows. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 10012–10022, 2021.
- [6] C. Tsai et al. Efficiently localizing knee joint injury with elnet on mri. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 432–441, 2020.
- [7] M. J. Awan et al. Mvanet: Multi-view attention network for anterior cruciate ligament tear detection on knee mri. *Diagnostics*, 12(4):891, 2022.
- [8] S. Wang et al. Sgnet: Selective group attention network for knee joint abnormality classification. *Medical Physics*, 50(5):2912–2925, 2023.
- [9] M. Azcona et al. Anterior cruciate ligament tear detection in mri scans using deep learning classification with slice-level aggregation. *IEEE Access*, 8:112344–112353, 2020.
- [10] H. Al Ghothani and Y. Zhang. Attention-guided cnn for knee joint injury diagnosis on the mrnet dataset. *Journal of Imaging*, 9(2):34, 2023.
- [11] T. Chen et al. Dual-branch efficientnet for anterior cruciate ligament injury classification. *Computerized Medical Imaging and Graphics*, 92:101962, 2021.
- [12] G. Joshi and L. Suganthi. Kneexnet: A graph convolutional network for knee joint injury classification and localized abnormality detection on mrnet dataset. *Medical Image Analysis*, 84:102715, 2023.
- [13] M. Martinez et al. An adapted 3d resnet-50 for magnetic resonance imaging classification of knee joint injuries. *Computers in Biology and Medicine*, 145:105423, 2022.

-
- [14] Z. Wang et al. Weighted multi-view convolutional neural networks for anterior cruciate ligament tear detection. *BMC Medical Imaging*, 21(1):142, 2021.